



Douglas Pereira de Araujo

Felipe Dal Molin

Gabriela Germana Da Silva

Samuel Regis Nascimento Barbosa

Projeto Aplicado III

Algoritmo de Recomendação para indicação de Livros em Python

São Paulo

2023



Sumário

Introdução.....	3
Cronograma.....	4
Bibliografia	5
Bibliotecas Utilizadas no Projeto	5
Modelagem dos dados	6
Análise Exploratória dos dados	11
Construção do Modelo	21



Introdução:

Descoberta de Conhecimento em Bancos de Dados (KDD), ou Knowledge Discovery in Databases, é um processo interdisciplinar que abrange diversas etapas, desde a seleção e preparação dos dados até a interpretação dos resultados obtidos. É um campo que combina elementos da mineração de dados, aprendizado de máquina, estatísticas e outras disciplinas relacionadas, visando extrair informações úteis e ocultas a partir de grandes conjuntos de dados. O processo de KDD envolve a identificação de padrões, tendências e relações nos dados, resultando na geração de conhecimento que pode ser aplicado em tomadas de decisão, previsões e outras análises significativas.

Os algoritmos de recomendação têm um papel fundamental na análise de dados, especialmente no contexto do comércio eletrônico, plataformas de streaming, redes sociais e muitos outros sistemas onde há uma abundância de opções disponíveis para os usuários. Esses algoritmos buscam prever as preferências ou interesses dos usuários e, com base nessa previsão, sugerir itens ou conteúdos que possam ser do interesse deles. A popularidade e a importância dos algoritmos de recomendação cresceram exponencialmente à medida que as empresas buscam personalizar a experiência do usuário e melhorar a satisfação.

Nesse contexto da análise de dados, escolhemos a aplicação de algoritmos de recomendação para livros, que tem desempenhado um papel significativo em aprimorar a experiência dos leitores e promover a descoberta literária. Esse sistema especializado visa entender os gostos e preferências de leitores individuais, utilizando dados como histórico de leitura, classificações e interações com outros livros. Com base nessas informações esses algoritmos buscam aprender padrões e relações nos dados de treinamento para fazer previsões ou classificações precisas em novos dados, com base nas informações aprendidas durante o treinamento, onde irão identificar padrões e relações entre títulos, autores e gêneros. Esses sistemas de recomendação para livros não apenas facilitam a descoberta de novas obras, mas também contribuem para a construção de uma comunidade de leitores ao redor de interesses comuns. Ao combinar os princípios de KDD e algoritmos de recomendação, esses sistemas proporcionam uma experiência de leitura mais enriquecedora e diversificada, conectando leitores a livros que poderiam passar despercebidos em meio a uma vasta oferta literária.

Os princípios e os processos envolvidos na descoberta de padrões úteis nos dados, abrangem duas técnicas de identificação das informações. Os algoritmos supervisionados são projetados para trabalhar com dados rotulados, ou seja, conjuntos de dados em que cada exemplo é associado a um rótulo ou classe conhecida. Em contraste, os algoritmos não supervisionados lidam com dados não rotulados, explorando a estrutura subjacente dos dados para identificar padrões, agrupamentos e características



intrínsecas. Eles buscam organizar os dados de maneira significativa, revelando informações sobre similaridades e diferenças entre os exemplos sem a orientação de rótulos predefinidos. Enquanto os algoritmos supervisionados são aplicados em tarefas de classificação e regressão, os algoritmos não supervisionados são frequentemente utilizados em tarefas de clusterização proporcionando uma compreensão mais profunda dos dados e suas relações.

Cronograma:

Etapa	Descrição da atividade	Prazo
Etapa 1	Montagem do grupo Escolha da temática Escolha do Dataset Organização dos documentos no repositório	10/08 a 27/08
Etapa 2	Elaboração da proposta analítica Tratar e preparar a base de dados Definir a técnica para o treinamento do modelo Validação do Modelo Descrever o referencial teórico para a elaboração do projeto. Apresentação dos Scripts da Análise Exploratória em Python Construção gráfica dos resultados	28/08 a 21/09
Etapa 3	Ajustar o pipeline de treinamento para o resultado final Reavaliar o desempenho do modelo. Descrever a metodologia aplicada.	23/09 a 20/10
Etapa 4	Analisar os resultados obtidos Descrever e documentar os resultados Finalização do data Storytelling Descrever e documentar as conclusões e os trabalhos futuros. Ajuste do relatório final Realizar a gravação da apresentação do projeto em vídeo Organizar todos os documentos no repositórios Entregar todos os arquivos do projeto Vídeo de apresentação do projeto	24/10 a 01/11



Bibliotecas utilizadas no modelo:

Pandas;

Numpy;

Matplotlib;

Seaborn;

Scipy;

Requests;

Sklearn;

Pillow;

Warnings

Importação das Bibliotecas

```
# Importação de Bibliotecas
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import plotly.express as px
import warnings

# Configurações Iniciais
warnings.filterwarnings('ignore')
pd.set_option('display.max_rows', 100)
pd.set_option('display.max_columns', 50)
plt.rcParams['figure.figsize'] = (15, 6)
plt.style.use('seaborn-darkgrid')
```

*

```
# Ler os dados
Dados_Livros = pd.read_csv('Books.csv')
Dados_Avaliacao = pd.read_csv('Ratings.csv')
Dados_Usuario = pd.read_csv('Users.csv')

# Dimensão [ Linhas, Colunas ]
Dados_Livros.shape, Dados_Avaliacao.shape, Dados_Usuario.shape
```



Modelagem dos dados

Na fase de modelagem do nosso projeto, um passo crucial foi combinar diferentes conjuntos de dados. Essa etapa, chamada de cruzamento de dados, foi essencial para criar o modelo que recomendará livros aos usuários.

Cruzamento dos Dados

1º Cruzamento:

No primeiro cruzamento de dados, juntamos informações sobre livros e avaliações dos usuários. Esses dados foram combinados para criar uma base que relaciona livros e as opiniões dos leitores. Isso foi feito usando o número de identificação dos livros (ISBN) como chave para conectar as informações.

2º Cruzamento:

No segundo cruzamento de dados, adicionamos informações sobre os próprios usuários. Combinamos os dados já consolidados no primeiro cruzamento com os perfis dos leitores. Ao conectar essas informações usando os IDs dos usuários, conseguimos entender melhor as preferências individuais de leitura. Isso tornou nosso modelo de recomendação altamente personalizado, levando em conta as preferências únicas de cada usuário.

Esses cruzamentos criaram uma tabela única que se tornou a base do nosso modelo de recomendação de livros. Esta tabela contém informações sobre livros, avaliações de usuários e os perfis dos leitores.

*

```
# Cruzamentos dos dados

# 1º Cruzamento
Tab_Cruzada = Dados_Livros.merge( Dados_Avaliacao, how='inner', on='ISBN')

# 2º Cruzamento
Tab_Cruzada = Tab_Cruzada.merge( Dados_Usuario, how='inner', on='User-ID')

# Dimensão
Tab_Cruzada.shape
```



*

```
# Verificar
Tab_Cruzada.head()
```

	ISBN	Book-Title	Book-Author	Year-Of-Publication	Publisher	Image-URL-S	Image-URL-M
0	0195153448	Classical Mythology	Mark P. O. Morford	2002	Oxford University Press	http://images.amazon.com/images/P/0195153448.0...	http://images.amazon.com/images/P/0195153448.0... http://image
1	0002005018	Clara Callan	Richard Bruce Wright	2001	HarperFlamingo Canada	http://images.amazon.com/images/P/0002005018.0...	http://images.amazon.com/images/P/0002005018.0... http://image
2	0060973129	Decision in Normandy	Carlo D'Este	1991	HarperPerennial	http://images.amazon.com/images/P/0060973129.0...	http://images.amazon.com/images/P/0060973129.0... http://image
3	0374157065	Flu: The Story of the Great Influenza Pandemic...	Gina Bari Kolata	1999	Farrar Straus & Giroux	http://images.amazon.com/images/P/0374157065.0...	http://images.amazon.com/images/P/0374157065.0... http://image
4	0393045218	The Mummies of Urumchi	E. J. W. Barber	1999	W. W. Norton & Company	http://images.amazon.com/images/P/0393045218.0...	http://images.amazon.com/images/P/0393045218.0... http://image

*

```
# Formato das Colunas
Tab_Cruzada.dtypes
```

```
ISBN                object
Book-Title          object
Book-Author        object
Year-Of-Publication float64
Publisher           object
Image-URL-S         object
Image-URL-M         object
Image-URL-L         object
User-ID            int64
Book-Rating         int64
Location            object
Age                float64
dtype: object
```

*

```
# Verificando
Tab_Cruzada['Location'].head(5)
```

```
0    stockton, california, usa
1    timmins, ontario, canada
2    timmins, ontario, canada
3    timmins, ontario, canada
4    timmins, ontario, canada
Name: Location, dtype: object
```



*

```
# Verificando
Tab_Cruzada['Location'].tail(5)

1031131          venice, florida, usa
1031132          tioga, pennsylvania, usa
1031133          madrid, madrid, spain
1031134          grand prairie, texas, usa
1031135    bielefeld, nordrhein-westfalen, germany
Name: Location, dtype: object
```

*

```
# Tecnica de tratamento de texto
def Extrair_Pais( Regiao ):
    '''
        Função para extrair o nome do pais na coluna região
    '''
    # Incluindo a inforção
    Registro = Regiao
    # Fatiar
    Registro = Regiao.split(',')
    # Buscar
    Fracao = Registro[-1].upper()
    #Retorno
    return Fracao

# Criando a coluna
Tab_Cruzada['Pais'] = Tab_Cruzada['Location'].apply( Extrair_Pais )

# Verificando
Tab_Cruzada.head()
```

	ISBN	Book- Title	Book- Author	Year-Of- Publication	Publisher	Image-URL-S		
0	0195153448	Classical Mythology	Mark P. O. Morford	2002.0	Oxford University Press	http://images.amazon.com/images/P/0195153448.0...	http://images.amazon.com/images/P/0195153448.0...	http://image
1	0002005018	Clara Callan	Richard Bruce Wright	2001.0	HarperFlamingo Canada	http://images.amazon.com/images/P/0002005018.0...	http://images.amazon.com/images/P/0002005018.0...	http://image
2	0060973129	Decision in Normandy	Carlo D'Este	1991.0	HarperPerennial	http://images.amazon.com/images/P/0060973129.0...	http://images.amazon.com/images/P/0060973129.0...	http://image
3	0374157065	Flu: The Story of the Great Influenza Pandemic...	Gina Bari Kolata	1999.0	Farrar Straus & Giroux	http://images.amazon.com/images/P/0374157065.0...	http://images.amazon.com/images/P/0374157065.0...	http://image
4	0393045218	The Mummies of Urumchi	E. J. W. Barber	1999.0	W. W. Norton & Company	http://images.amazon.com/images/P/0393045218.0...	http://images.amazon.com/images/P/0393045218.0...	http://image



*

```
# Nulos
Tab_Cruzada.isnull().sum()

ISBN                0
Book-Title          0
Book-Author        1
Year-Of-Publication 4
Publisher           2
Image-URL-S         0
Image-URL-M         0
Image-URL-L         4
User-ID            0
Book-Rating         0
Location            0
Age                277835
Pais               0
dtype: int64
```

*

```
# Unicos
Tab_Cruzada.nunique()

ISBN                270151
Book-Title          241071
Book-Author        101588
Year-Of-Publication 116
Publisher           16729
Image-URL-S         269842
Image-URL-M         269842
Image-URL-L         269839
User-ID            92106
Book-Rating         11
Location            22480
Age                141
Pais               288
dtype: int64
```



*

```
# Renomear as colunas
Tab_Cruzada.rename(
    columns={
        'Book-Title' : 'Titulo',
        'Book-Author' : 'Autor',
        'Year-Of-Publication' : 'Ano_Publicacao',
        'Publisher' : 'Editora',
        'User-ID' : 'Id_Cliente',
        'Book-Rating' : 'Avaliacao',
        'Location' : 'Localizacao',
        'Age' : 'Idade'
    }, inplace=True
)

# Verificar
Tab_Cruzada.columns

Index(['ISBN', 'Titulo', 'Autor', 'Ano_Publicacao', 'Editora', 'Image-URL-S',
      'Image-URL-M', 'Image-URL-L', 'Id_Cliente', 'Avaliacao', 'Localizacao',
      'Idade', 'Pais'],
      dtype='object')
```



Análise Exploratória dos dados:

*

```
# Analise descritiva  
Tab_Cruzada.describe()
```

	Ano_Publicacao	Id_Cliente	Avaliacao	Idade
count	1.031132e+06	1.031136e+06	1.031136e+06	753301.000000
mean	1.968195e+03	1.405945e+05	2.839051e+00	37.397648
std	2.311015e+02	8.052466e+04	3.854157e+00	14.098254
min	0.000000e+00	2.000000e+00	0.000000e+00	0.000000
25%	1.992000e+03	7.041500e+04	0.000000e+00	28.000000
50%	1.997000e+03	1.412100e+05	0.000000e+00	35.000000
75%	2.001000e+03	2.114260e+05	7.000000e+00	45.000000
max	2.050000e+03	2.788540e+05	1.000000e+01	244.000000

*

```
# Remover as avaliações zeradas  
Tab_Cruzada = Tab_Cruzada.loc[ Tab_Cruzada['Avaliacao'] > 0 ]  
  
# Verificar  
Tab_Cruzada.isnull().sum(), Tab_Cruzada.shape
```

```
(ISBN  
Titulo  
Autor  
Ano_Publicacao  
Editora  
Image-URL-S  
Image-URL-M  
Image-URL-L  
Id_Cliente  
Avaliacao  
Localizacao  
Idade  
Pais  
dtype: int64, (383842, 13))
```


*

```
# Verificar
Tab_Cruzada['Avaliacao'].describe()
```

```
count      383842.000000
mean         7.626701
std          1.841339
min          1.000000
25%          7.000000
50%          8.000000
75%          9.000000
max         10.000000
Name: Avaliacao, dtype: float64
```

*

```
# Analise grafica
plt.title('Analisando a avaliação')
sns.boxplot( data=Tab_Cruzada, x='Avaliacao');
```



*

```
# Analise
Analise = Tab_Cruzada.groupby( by=['Titulo'] ).agg(
    Quantidade = ('Titulo', 'count'),
    Media = ('Avaliacao', 'mean'),
    Max = ('Avaliacao', 'max'),
    Min = ('Avaliacao', 'min'),
    Mediana = ('Avaliacao', 'median'),
)

# Verificando
Analise.head()
```

	Quantidade	Media	Max	Min	Mediana
Titulo					
A Light in the Storm: The Civil War Diary of Amelia Martin, Fenwick Island, Delaware, 1861 (Dear America)	1	9.000000	9	9	9.0
Ask Lily (Young Women of Faith: Lily Series, Book 5)	1	8.000000	8	8	8.0
Dark Justice	1	10.000000	10	10	10.0
Earth Prayers From around the World: 365 Prayers, Poems, and Invocations for Honoring the Earth	7	7.142857	10	1	7.0
Final Fantasy Anthology: Official Strategy Guide (Brady Games)	2	10.000000	10	10	10.0

*

```
# Verificar
Analise.sort_values('Quantidade', ascending=False ).head()
```

	Quantidade	Media	Max	Min	Mediana
Titulo					
The Lovely Bones: A Novel	707	8.185290	10	1	8.0
Wild Animus	581	4.390706	10	1	4.0
The Da Vinci Code	494	8.439271	10	1	9.0
The Secret Life of Bees	406	8.477833	10	2	9.0
The Nanny Diaries: A Novel	393	7.437659	10	1	8.0



*

```
# Vericar
Analise.sort_values(['Media', 'Quantidade'], ascending=False).head()
```


	Quantidade	Media	Max	Min	Mediana
Titulo					
Postmarked Yesteryear: 30 Rare Holiday Postcards	11	10.0	10	10	10.0
The Sneetches and Other Stories	8	10.0	10	10	10.0
Natural California: A Postcard Book	7	10.0	10	10	10.0
Uncle John's Supremely Satisfying Bathroom Reader (Uncle John's Bathroom Reader)	7	10.0	10	10	10.0
Oh, the Thinks You Can Think! (I Can Read It All by Myself Beginner Books)	6	10.0	10	10	10.0

*

```
# Analise Qtd x Avaliacao

px.scatter(
  # Dados
  data_frame=Analise,
  # Parametros
  x='Quantidade', y='Media',
  # Titulo
  title='Média x Quantidade - Titulos',
  # Upgrade
  # marginal_y='rug', marginal_x='histogram'
)
```

Média x Quantidade - Titulos



*

```
# Correlação  
Analise.corr()
```

	Quantidade	Media	Max	Min	Mediana
Quantidade	1.000000	0.018880	0.175572	-0.251497	0.036604
Media	0.018880	1.000000	0.889722	0.842385	0.989839
Max	0.175572	0.889722	1.000000	0.530760	0.887792
Min	-0.251497	0.842385	0.530760	1.000000	0.804023
Mediana	0.036604	0.989839	0.887792	0.804023	1.000000

*

```
# Analise  
Analise['Quantidade'].describe()
```

```
count      135567.000000  
mean         2.831382  
std         9.135691  
min         1.000000  
25%         1.000000  
50%         1.000000  
75%         2.000000  
max        707.000000  
Name: Quantidade, dtype: float64
```



*

```
#
def Classificacao_Quantidade( Quantidade ):
    ...
    Agrupar a quantidade
    ...

    if int( Quantidade ) <= 5:
        return '1-5 Avaliações'

    elif int( Quantidade ) <=10:
        return '6-10 Avaliações'

    elif int(Quantidade) <= 50:
        return '11-50 Avaliações'

    elif int(Quantidade) <= 100:
        return '51-100 Avaliações'

    else:
        return '>101 Avaliações'


# Aplicação
Pizza = Analise['Quantidade'].apply( Classificacao_Quantidade ).value_counts( normalize=True )

# Tranformar em um DataFrame
Pizza = pd.DataFrame( Pizza ).reset_index()

# Plot
px.pie(
    # DAdos
    data_frame=Pizza,
    # Parametros
    names='index', values='Quantidade',
    # Titulo
    title='Divisão das Quantidades'
)
```




Distribuição das quantidades em cada categoria



```
# Verificando
Pizza
```

	index	Quantidade
0	1-5 Avaliações	0.920010
1	6-10 Avaliações	0.042783
2	11-50 Avaliações	0.032589
3	51-100 Avaliações	0.003201
4	>101 Avaliações	0.001416



*

```
# Publicação
Anlase_Ano = Tab_Cruzada['Ano_Publicacao'].value_counts().sort_index().reset_index()

# Verificando
Anlase_Ano.describe()
```

	index	Ano_Publicacao
count	105.000000	105.000000
mean	1934.028571	3655.628571
std	210.090432	8051.797181
min	0.000000	1.000000
25%	1937.000000	4.000000
50%	1963.000000	63.000000
75%	1989.000000	1652.000000
max	2050.000000	37986.000000

*

```
# Plot

# Filtrando o ano
Filtro = Anlase_Ano.loc[ (Anlase_Ano['index'] > 1990) & ( Anlase_Ano['index'] < 2020 ) ]

# Plot
plt.title('Analisando ano de publicação')
plt.bar( Filtro['index'], Filtro['Ano_Publicacao'] );
```





*

```
Tab_Cruzada.columns
```

```
Index(['ISBN', 'Titulo', 'Autor', 'Ano_Publicacao', 'Editora', 'Image-URL-S',  
      'Image-URL-M', 'Image-URL-L', 'Id_Cliente', 'Avaliacao', 'Localizacao',  
      'Idade', 'Pais'],  
      dtype='object')
```

*

```
# Rankg dos Autores  
Tab_Cruzada.groupby( by='Autor' ).agg(  
    Quantidade = ('Avaliacao', 'count'),  
    Media = ('Avaliacao', 'mean'),  
) .sort_values('Quantidade', ascending=False ).head(10)
```

	Quantidade	Media
Autor		
Stephen King	4639	7.815046
Nora Roberts	2938	7.629680
John Grisham	2550	7.523137
James Patterson	2387	7.697947
J. K. Rowling	1746	8.970218
Mary Higgins Clark	1677	7.503280
Janet Evanovich	1490	7.944966
Dean R. Koontz	1475	7.572203
Anne Rice	1245	7.387952
Sue Grafton	1235	7.722267

*

```
# Concentração das avaliações  
Tab_Cruzada['Pais'].value_counts( normalize=True ).head(10) * 100
```

```
USA          68.378135  
CANADA       9.267876  
UNITED KINGDOM  3.854190  
GERMANY      3.165625  
              2.737845  
SPAIN        1.874990  
AUSTRALIA    1.821322  
N/A          1.811943  
FRANCE       1.207789  
PORTUGAL     0.897505  
Name: Pais, dtype: float64
```



*


```
# Concentração das avaliações
Tab_Cruzada['Pais'].value_counts( normalize=True ).cumsum().head(10) * 100
```

USA	68.378135
CANADA	77.646011
UNITED KINGDOM	81.500201
GERMANY	84.665826
	87.403671
SPAIN	89.278662
AUSTRALIA	91.099984
N/A	92.911927
FRANCE	94.119716
PORTUGAL	95.017221

Name: Pais, dtype: float64

*

```
# Idade
plt.title('Análise das idades')
sns.boxplot( data=Tab_Cruzada, x='Idade' );
```





Construção do modelo:

O Aprendizado por Representação é a busca por melhores representações de dados em algoritmos, muitas vezes não supervisionados. Exemplos incluem Análise de Componentes Principais e Clustering. Esses métodos transformam dados de entrada para preservar informações úteis, útil como pré-processamento para classificação e previsão, permitindo reconstrução de dados de origens desconhecidas. Algoritmos buscam representações de baixa dimensão, esparsas ou hierarquias em níveis abstratos. Essencial para máquinas inteligentes que desvendam fatores subjacentes dos dados.

*

```
# Ajustar ( Avaliação dos Livros --> Tab_Cruzada )

# Ajustando a Tabela de Avaliacoões
Avaliacoões = Analise.reset_index().iloc[:, 0:2]

# Cruzando os dados
Tab_Final = Tab_Cruzada.merge( Avaliacoões, how='inner', on='Titulo' )

# Verificando
Tab_Final.head()
```

	ISBN	Titulo	Autor	Ano_Publicacao	Editora	Image-URL-S	Image-URL-M	Image-URL-L	Id_Client
0	0002005018	Clara Callan	Richard Bruce Wright	2001.0	HarperFlamingo Canada	http://images.amazon.com/images/P/0002005018.0...	http://images.amazon.com/images/P/0002005018.0...	http://images.amazon.com/images/P/0002005018.0...	
1	0002005018	Clara Callan	Richard Bruce Wright	2001.0	HarperFlamingo Canada	http://images.amazon.com/images/P/0002005018.0...	http://images.amazon.com/images/P/0002005018.0...	http://images.amazon.com/images/P/0002005018.0...	1167
2	0002005018	Clara Callan	Richard Bruce Wright	2001.0	HarperFlamingo Canada	http://images.amazon.com/images/P/0002005018.0...	http://images.amazon.com/images/P/0002005018.0...	http://images.amazon.com/images/P/0002005018.0...	6754
3	0002005018	Clara Callan	Richard Bruce Wright	2001.0	HarperFlamingo Canada	http://images.amazon.com/images/P/0002005018.0...	http://images.amazon.com/images/P/0002005018.0...	http://images.amazon.com/images/P/0002005018.0...	11686
4	0002005018	Clara Callan	Richard Bruce Wright	2001.0	HarperFlamingo Canada	http://images.amazon.com/images/P/0002005018.0...	http://images.amazon.com/images/P/0002005018.0...	http://images.amazon.com/images/P/0002005018.0...	12362

*

```
# Filtrar
Livros_Avaliados = Tab_Final.loc[ Tab_Final['Quantidade'] >= 50 ]

# Dimensao
Livros_Avaliados.shape

(65477, 14)
```

*

```
# Duplicados
Livros_Avaliados.duplicated().sum()
```

0



*

```
# Gerar a Matriz
Matriz = Livros_Avaliados.pivot_table( values='Avaliacao', index='Titulo', columns='Id_Cliente' )

# Retirar os NAN
Matriz.fillna( 0, inplace=True)

# Verificar
Matriz.head()
```

Id_Cliente	9	16	26	32	42	51	91	97	99	114	125	165	169	183	185	224	226	242	243	244	254	256	272	280	332	...	278633	278641	278645	278653	278663	278672	278683	278698	278723	278732
Titulo																																				
1984	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
1st to Die: A Novel	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
2nd Chance	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
4 Blondes	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
84 Charing Cross Road	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0

5 rows × 24863 columns

*

```
# Verificando
Tab_Cruzada.loc[ Tab_Cruzada['Titulo'] == '1984' ].head()
```

	ISBN	Titulo	Autor	Ano_Publicacao	Editora	Image-URL-5		Image-URL-M		Image-URL-L		Id_Cliente
2713	0452262933	1984	George Orwell	1983.0	Plume Books	http://images.amazon.com/images/P/0452262933.0...	http://images.amazon.com/images/P/0452262933.0...	http://images.amazon.com/images/P/0452262933.0...	http://images.amazon.com/images/P/0452262933.0...	http://images.amazon.com/images/P/0452262933.0...	http://images.amazon.com/images/P/0452262933.0...	11676
33641	0451519841	1984	George Orwell	1980.0	New Amer Library	http://images.amazon.com/images/P/0451519841.0...	http://images.amazon.com/images/P/0451519841.0...	http://images.amazon.com/images/P/0451519841.0...	http://images.amazon.com/images/P/0451519841.0...	http://images.amazon.com/images/P/0451519841.0...	http://images.amazon.com/images/P/0451519841.0...	7346
36405	0451524934	1984	George Orwell	1990.0	Signet Book	http://images.amazon.com/images/P/0451524934.0...	http://images.amazon.com/images/P/0451524934.0...	http://images.amazon.com/images/P/0451524934.0...	http://images.amazon.com/images/P/0451524934.0...	http://images.amazon.com/images/P/0451524934.0...	http://images.amazon.com/images/P/0451524934.0...	16795
106795	0451519841	1984	George Orwell	1980.0	New Amer Library	http://images.amazon.com/images/P/0451519841.0...	http://images.amazon.com/images/P/0451519841.0...	http://images.amazon.com/images/P/0451519841.0...	http://images.amazon.com/images/P/0451519841.0...	http://images.amazon.com/images/P/0451519841.0...	http://images.amazon.com/images/P/0451519841.0...	197364
129342	0451524934	1984	George Orwell	1990.0	Signet Book	http://images.amazon.com/images/P/0451524934.0...	http://images.amazon.com/images/P/0451524934.0...	http://images.amazon.com/images/P/0451524934.0...	http://images.amazon.com/images/P/0451524934.0...	http://images.amazon.com/images/P/0451524934.0...	http://images.amazon.com/images/P/0451524934.0...	240567

*

```
# Transformação para vetores
from scipy.sparse import csc_matrix
Matriz_Sparse = csc_matrix( Matriz )

Matriz_Sparse
```

```
<651x24863 sparse matrix of type '<class 'numpy.float64'>'
with 65081 stored elements in Compressed Sparse Column format>
```

*

```
# Exemplo da função
csc_matrix( (4, 4), dtype=np.int8 ).toarray()

array([[0, 0, 0, 0],
       [0, 0, 0, 0],
       [0, 0, 0, 0],
       [0, 0, 0, 0]], dtype=int8)
```

*

```
# Criar o Modelo
from sklearn.neighbors import NearestNeighbors

# Parametros
Modelo = NearestNeighbors(
    # Quantidade de recomendações
    n_neighbors=5,
    # Algoritmo
    algorithm='brute',
    # metrica de distancia
    metric='minkowski'
)

# Fitrar o modelo
Modelo.fit( Matriz_Sparse )

NearestNeighbors(algorithm='brute')
```

*

```
# Recomendações
# Escolher_Livro

# Descobrir Libros Harry
for Posicao, Titulo in enumerate(Matriz.index):

    # Harry
    if 'Harry' in Titulo:
        print( Posicao, Titulo )

213 Harry Potter and the Chamber of Secrets (Book 2)
214 Harry Potter and the Goblet of Fire (Book 4)
215 Harry Potter and the Order of the Phoenix (Book 5)
216 Harry Potter and the Prisoner of Azkaban (Book 3)
217 Harry Potter and the Sorcerer's Stone (Book 1)
218 Harry Potter and the Sorcerer's Stone (Harry Potter (Paperback))
```

*

```
# Selecionando o Livro ##### CLIENTE COMPROU !!!!! #####
Selecionar_Livro = Matriz.iloc[ 213, :].values.reshape( 1, -1 )

# Previsão do Modelo
Distancia, Recomendacao = Modelo.kneighbors( Selecionar_Livro )

## AVALIAÇÃO / RENTABILIDADE / SERIES / NOTICIAS

#### RECOMENDAÇÕES #####
# Ver as sugestões
for Loop in range( len(Recomendacao) ):

    print( Matriz.index[ Recomendacao[Loop] ] )

Index(['Harry Potter and the Chamber of Secrets (Book 2)',
      'Harry Potter and the Prisoner of Azkaban (Book 3)',
      'Harry Potter and the Goblet of Fire (Book 4)',
      'Harry Potter and the Sorcerer's Stone (Book 1)',
      'Don't Stand Too Close to a Naked Man'],
      dtype='object', name='Titulo')
```



*

Distancia

```
array([[ 0.          , 158.46714296, 158.8951991 , 158.7714115 ,  
        165.39481384 ]])
```

Bibliografia:

[Book Recommendation Dataset | Kaggle](#)